

因果分析

(根据理解，学习与整理自知识星球)

一、因果分析概述.....	2
1、因果分析.....	2
2、因果问题.....	3
3、拆解因果分析.....	3
4、因果发现.....	3
4.1 因果发现的方法.....	4
5、因果推理.....	4
5.1 用于因果推断的办法.....	4
5.1.1 实验方法.....	4
5.1.2 非实验方法.....	5
二、A/B 实验.....	5
1、统计原理.....	5
1.1 【假设】.....	6
1.2 【检验方法】.....	7
1.3 【检验假设正确性】.....	10
2、A/B 实验最小样本量的确定和计算.....	11
2.1 计算最小样本量.....	12
2.2 样本量影响因素与 n 的关系.....	12
2.3 关于最小样本量问题.....	13
3、A/B 实验实操常见问题及处理方法.....	14
3.1 检验灵敏度(MDE).....	14
3.2 检验灵敏度(MDE)的计算.....	14
3.3 如何使用检验灵敏度(MDE).....	14
3.4 提升实验显著性的方法.....	15
4、AB 实验流程.....	17
三、倾向得分匹配 PSM 和双重差分 DID.....	17
1、模型原理.....	18
2、建模过程.....	18
3、模型优点与局限性.....	19
4、案例.....	19
四、因果推断可靠性检验方法.....	20
1、模型完备性检验-AUC 值.....	21
1.1 概念:.....	21
1.2 AUC 不符预期 常用归因视角与优化方法.....	22
2、匹配组的平衡性检验（共同支撑分析、标准化偏差分析）.....	23
2.1 平衡性检验的目的和原理.....	23
2.2 平衡性检验方法实现&结果解读.....	23
2.3 平衡性检验结果不符预期如何优化.....	24
3、匹配结果的稳健性检验（反驳性检验、敏感性分析）.....	24

3.1 反驳性检验	24
3.2 敏感性分析（基于 gamma 为例）	25
4、总结	25
五、 异动分析（果到因）	25
1、进行异动分析的原因	25
2、异动分析的场景	26
3、 核心武器：贡献度的计算	26
3.1 方法一：加法型贡献度计算 (Additive Contribution)	26
3.2 方法二：乘法型贡献分解 (Multiplicative Decomposition - Log Transformation)	27
3.3 方法三：综合贡献计算法	28
3.4 总结	29

一、因果分析概述

1、因果分析

因果分析旨在从数据中发现真正的原因和结果。在许多情况下，相关性可能是因果关系和混杂关联的结合。例如，假设我们观察到携带打火机的人更容易患肺癌。携带打火机会导致肺癌吗？不，事实证明，吸烟是导致携带打火机和患肺癌的混杂因素。

在行业中，因果分析可以帮助我们了解功能变化对业务指标的影响。它可以回答以下问题：“如果我更改变量 X（例如更新推荐模型），会发生什么？我的结果变量 Y（例如用户满意度或参与度指标）会发生多大变化？”通过了解观察到的结果背后的原因，我们可以确定

实现预期结果所需的行动。

2、因果问题

在商业世界中，我们还面临许多因果问题，例如：

- 新的营销活动对销售增长贡献有多大？
- 哪些因素导致客户流失？
- 我们如何提高平台的用户参与度？

在许多情况下，我们会进行相关性分析来回答这些问题。例如，我们可能会比较新功能发布前后的销售情况，以估算由此带来的收入增长。或者，在其他情况下，我们可以建立一个机器学习模型，根据关联模式预测结果。

但这是正确的方法吗？如果多个功能捆绑在发布中会怎么样？如果在功能发布之前购买产品的客户与在功能发布之后购买产品的客户不同会怎么样？如果销售额的增长纯粹是由于季节性因素，与新功能无关，该怎么办？**由于有这么多变化的因素，很难断定观察到的相关性是否真的是因果关系。**

■ 因果问题的分类

类型 1: 哪些因素/干预导致结果？

商业示例：

- 哪些因素导致用户留存率下降？
- 哪些营销渠道正在为我们的网站带来流量？

类型 2: 治疗 (X) 对结果 (Y) 的影响有多大？

商业示例：

- 新功能在多大程度上提高了用户参与度？
- 价格变动对销售量有何影响？

3、拆解因果分析

因果分析可以分为两个主要子领域，每个子领域对应上述一个因果问题：

● 【因果发现】

因果发现涉及从数据中识别潜在的因果结构。例如，它通过分析应用程序数据来揭示通知、用户界面设计和内容加载速度等变量之间的关系，从而帮助回答“哪些因素影响用户参与度？”等问题。（**识别潜在因果结构-对应类型 1**）

● 【因果推理】

因果推理侧重于确定特定因素对结果的影响程度。例如，它可以回答诸如“个性化推送通知在多大程度上增强了用户参与度？”之类的问题。这个子领域包括实验等方法，其中使用受控实验（例如随机对照试验）来确定因果关系。（**确定特定因素对结果的影响程度-对应类型 2**）

4、因果发现

因果发现可以帮助回答几个重要问题：

- 哪些变量对某个结果有因果关系？例如：确定推送通知和用户界面设计会影响用户参与度。
- 有哪些潜在的治疗或干预措施？例如：确定提高加载速度可以提高用户满意度。
- 数据中的因果路径是什么？示例：发现发送个性化推送通知会增加用户打开应用程序的可能性，从而提高用户参与度。

通过回答这些问题，因果发现可以使企业和研究人员了解驱动观察到的效果的机制，制定有

针对性的干预措施以改善结果，并制定进一步实验或因果推理分析的假设。

4.1 因果发现的方法

因果发现中通常使用几种方法，包括：

- 基于约束的方法：使用条件独立性检验推断因果关系的技术。
 - 基于分数的方法：根据评分标准寻找最佳拟合因果图的方法。
 - 功能因果模型 (FCM)：将效应变量表示为其直接原因和某些噪声项的函数的模型
- 通过利用这些方法，我们可以发现因果关系并做出数据驱动的决策，从而获得更好的结果。

5、因果推理

因果推理是一种用于确定治疗或干预对结果的影响的方法。在因果推理中，我们经常处理各种因果估计量（要估计的数量），例如：

- **平均治疗效果 (ATE)**：治疗对整个人群的平均效果。 $ATE = E[Y(1) - Y(0)]$
应用：新功能在多大程度上提高了用户参与度？
- **条件平均治疗效果 (CATE)**：治疗对人群中特定子群体的平均效果。 $CATE = E[Y(1) - Y(0) | X = x]$
应用：营销活动的效果在不同的客户群体中有何不同？
- **治疗对接受治疗者的平均治疗效果 (ATT)**：治疗对实际接受治疗者的平均效果。 $ATT = E[Y(1) - Y(0) | T = 1]$
应用：新的定向活动对客户保留有何影响？
- **个体治疗效果 (ITE)**：治疗对个体的影响。 $ITE = Y(1)_i - Y(0)_i$
应用：个性化推荐对个人用户的购买行为有何影响？

其中， $Y(1)$ 表示治疗下的结果， $Y(0)$ 表示未治疗的结果； $X = x$ 表示人口亚群； $T = 1$ 表示接受治疗的人群； i 表示个体。

5.1 用于因果推断的办法

因果推理中的两种主要方法：**实验方法**和**非实验方法**。

5.1.1 实验方法

实验是一种通过操纵一个或多个变量并观察对结果的影响来建立因果关系的方法。

最严格的实验形式之一是**随机对照试验 (RCT)**。在 RCT 中，参与者被随机分配到治疗组或对照组。这种随机化有助于确保各组除治疗外各方面均相似，从而隔离治疗效果。

5.1.2 非实验方法

- **观察法**：这些方法依赖于不操纵研究环境而收集的数据。它们旨在控制混杂因素以估计因果关系，并且在进行实验不切实际或不道德时特别有用。
- **实验设计**：当无法随机分配实验组和对照组时，准实验设计用于识别因果关系。它们试图模拟实验条件来估计因果关系。
- **反事实分析**：这涉及将观察到的结果与未采用治疗时可能发生的假设结果进行比较。
- 以下是一些常用的因果推理技术，它们属于观察方法、准实验设计和反事实分析类别。由于其中一些方法可能属于多个类别，我们将其列在下面：
- **倾向得分匹配 (PSM)**：根据相似特征将接受治疗的个体与未接受治疗的个体配对，以减少混杂变量造成的偏见。
- **工具变量 (IV)**：使用与治疗相关但与结果无直接关系（除通过治疗外）的变量，通过提供不受混杂因素影响的变异源来隔离因果关系。
- **双重机器学习 (DML)**：利用机器学习通过创建治疗和结果变量的“干净”版本来控制混杂因素，通过从混杂因素中减去估计效应，提供更准确的因果估计。
- **双重差异法 (DiD)**：比较治疗组和对照组之间结果随时间的变化，有助于控制随时间对两个组产生类似影响的混杂变量。
- **合成控制方法 (SC)**：通过组合多个未处理单元的数据构建合成控制组，以估计在没有处理的情况下处理单元会发生什么情况。
- **贝叶斯结构时间序列 (BSTS)**：使用贝叶斯方法对时间序列数据进行建模。通过将观察到的数据与反事实情景进行比较，可以推断出干预的效果，从而估计如果没有干预会发生什么。
- **不连续回归设计 (RDD)**：使用截止值或阈值来分配治疗。通过比较高于和低于此截止值的个体，RDD 估计因果效应，假设阈值附近的个体除了治疗外都是相似的。


二、A/B 实验

1、统计原理

日常工作中遇到过的指标，大致可以分为以下几类：

- **均值类指标**：人均使用时长、人均 GMV、人均投稿数等
- **概率类指标**：次日留存、付费率、投稿率等
- **分位数指标**：用户使用时长的中位数、用户付费金额的 25 分位数、95 分位数等
- **比率指标**：点击率、消耗率等

——» 在实际业务中常用的指标核心就是**前两类均值指标和概率指标**，



卡方和 Delta Method 适用范围有什么区别?

- 卡方 (或 z 检验) 用来检验比例指标 (eg. 次留), Delta Method 用来检验比率指标 (eg. 点击率);
- 核心区别在于比例指标在一个单元只有一个状态服从二项分布, 比率指标是靠两个指标相除形成的复合指标非线性不独立;
- 再理论些二者的差别来自于分流单元与分析单元不一致, 分析单元的信息被聚合导致;

在 A/B 实验中, 我们通常关注需实验组和对照组在关键指标 (如点击率、活跃天数、GMV 等) 上是否“有明显差异”。一般的我们引入统计学中的假设检验框架来量化差异是否具备统计显著性。下面总结了一些 AB 中常用的假设检验方法, 这些方法足以应对一般的 AB 评估任务。

A/B 测试的**理论基础是假设检验(Hypothesis Testing)**

假设检验中的“假设”包括零假设和备择假设两种, 而检验则指的是双样本检验 (AB 实验是针对两组样本据进行比较, 就用双样本检验)

1.1 【假设】

在业务场景的 A/B 测试中的**原假设建议是永远都是用双尾检验**, 即原假设中符号永远选择“=”, 而不去选择单侧检验, 这里这样做的原因主要有两个:

- 第一个原因: 双尾检验可以让数据自身在决策中发挥更大的作用。我们在实践中使用 A/B 测试, 就是希望能够通过数据来驱动决策。要尽量减少在使用数据前产生的任何主观想法来干扰数据发挥作用。所以双尾检验这种不需要我们明确谁大谁小的检验, 更能发挥数据的作用
- 第二个原因: **双尾检验可以帮助我们全面考虑变化带来的正、负面结果**。在实践中, 我们期望改变可以使指标朝着好的方向变化, 但是万一指标实际的变化与期望的正好相反呢? 这就可以体现双尾检验的优势了。**双尾检验可以同时照顾到正面和负面的结果, 更接近多变的现实情况。但是单尾检验只会适用于其中一种, 而且通常是我们期望的正面效果**

【假设前提】

正态分布和中心极限定理

均值类指标它的总体通常是服从正态分布, 概率类指标服从二项分布

由二项分布的性质可知: 当样本量较大时二项分布就近似服从正态分布。

此时有的同学可能就会问了, 不对啊我们游戏业务付费金额往往是二八分布 (20% 的人贡献了 80% 的充值), 这种情况下分布该如何得到保证呢? 这个时候就不得不让中心极限定理出场了

中心极限定理给我们提供了一个保证: **当样本量足够大时, 不管之前样本服从的是什么分布, 但均值变量是趋近于正态分布的**。这个理论基础霸道的告诉我们: 不管选的指标总体分布是什么, 它的均值的分布总会近似为正态分布

而日常中要检验的东西就是两个组的某个指标均值之间是否存在显著差异, 我们就能根据正

态分布的各种性质展开后续的检验工作

1.2 【检验方法】

选择T检验还是 Z 检验，主要看样本量的大小和是否知道总体方差 (Population Variance):

- 当不知道总体方差时，使用 T 检验
- 当已知总体方差，且样本量大于 30 时，使用 Z 检验
- 当已知总体方差，且样本量小于 30 时，使用 T 检验

在我们实际业务场景中，我们的样本量一般是远远大于 30 的，而在大样本下正态分布和 T 分布是近似的，为了方便计算，在实际业务场景中，我们都通用 Z 检验即可，基本上任何场景都可以这样去用

{计算显著性}

由中心极限定理我们可以有了强有力的保证:均值变量是趋近于正态分布的。又由正态分布的性质我们知道任何一个正态分布都可以通过标准化 (Standardization) 变成标准正态分布。而标准化的过程就是按照下面这个公式把随机变量 x 变为 Z 分数，进而可以完成 Z 统计量的计算最终得到指标的 P-value，判断得出指标是否显著


- 计算公式

指标类型	需要知道的信息	Z统计量计算公式	备注
均值类指标	对照组和实验组的样本量大小 对照组和实验组的均值水平大小 对照组和实验组的样本方差大小	$Z统计量 = \frac{ \mu_1 - \mu_2 }{\sqrt{\frac{\sigma_1^2}{N_1} + \frac{\sigma_2^2}{N_2}}}$	
比例类指标	对照组和实验组的样本量大小 对照组和实验组的比例大小	$Z统计量 = \frac{ P_1 - P_2 }{\sqrt{\frac{\sigma_1^2}{N_1} + \frac{\sigma_2^2}{N_2}}}$	比例类指标由二项分布的性质可以知道方差的大小= $P_1 * (1 - P_1)$

{t 检验}

t 检验是一种基于 t 分布的参数检验（总体均值检验），用来判断样本均值差异是否显著。常见的有单样本、独立样本和配对样本 t 检验。它通过计算 t 值和 p 值，来帮助我们在统计学意义上判断差异是否可靠

t 值的基本思想就是用样本均值的差异去除以标准误，衡量均值差异是否大到超出随机波动的范围。



对称性：t 分布和正态分布一样，以 0 为中心对称。

自由度 (df)：自由度越小，t 分布尾部越厚 (fatter tails)，极端值的概率更高。

——df=1 时，尾巴特别厚。随着 df 增大，t 分布逐渐接近标准正态分布。

用途：t 分布主要用在小样本、总体方差未知的情况下，用来构造置信区间或进行 t 检验

t 检验的公式会根据检验类型（单样本、独立样本、配对样本）稍有不同

2. 独立样本 t 检验

检验两个独立样本均值是否相等：

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

其中：

- $\bar{x}_1, \bar{x}_2$ = 两个样本均值
- s_1^2, s_2^2 = 两个样本方差
- n_1, n_2 = 两个样本量

如果假设两个样本方差相等，可以用合并方差公式：

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$$

然后：

$$t = \frac{\bar{x}_1 - \bar{x}_2}{s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

1. 单样本 t 检验

用来检验样本均值是否等于某个已知值 (μ_0)：

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

其中：

- $\bar{x}$ = 样本均值
- μ_0 = 假设的总体均值
- s = 样本标准差
- n = 样本量

3. 配对样本 t 检验

用于同一样本在两种条件下的比较（差值检验）：

$$t = \frac{\bar{d}}{s_d/\sqrt{n}}$$

其中：

- $\bar{d}$ = 配对差值的均值
- s_d = 配对差值的标准差
- n = 配对的数量

{z 检验}

z 检验是基于标准正态分布 (z 分布)的参数检验，常用于大样本或已知方差的情况，通过计算 z 值和 p 值来判断样本均值或比例是否与总体有显著差异

● 使用场景

常见的几类 z 检验：

单样本 z 检验：检验样本均值是否等于某个总体均值。


例：一个班级的平均身高是否等于全国平均身高 170cm。

双样本 z 检验：检验两个独立样本均值是否相等。

例：比较两家工厂生产的零件平均直径是否相同。

比例 z 检验：检验样本比例与总体比例是否存在显著差异。

例：某调查中支持某政策的人数比例是否与官方统计一致。



这里就是 z 分布（标准正态分布 $N(0,1)$ ）的图：

蓝色曲线是 z 分布，它就是均值 0、方差 1 的正态分布。（中心在 0，对称分布）

红色虚线标出了常用的临界值 $z = \pm 1.96$ （对应显著性水平 $\alpha=0.05$ ，95% 置信区间）。

关键特征

1. 对称性：以 0 为中心，两边对称。
2. 标准化：任何正态分布都可以通过标准化变成 z 分布。

$$z = \frac{x - \mu}{\sigma}$$

3. 在假设检验中的作用：
 - 如果计算得到的 z 值落在 ± 1.96 之外 $\rightarrow p < 0.05 \rightarrow$ 拒绝原假设。
 - 如果落在 ± 1.96 之内 $\rightarrow$ 接受原假设。

● 使用方法

1. 提出假设

- H_0 (原假设)：样本均值等于总体均值（或两组均值相等）。
- H_1 (备择假设)：两者不相等。

2. 计算 z 统计量

单样本情况公式：

$$z = \frac{\bar{x} - \mu}{\sigma / \sqrt{n}}$$

- $\bar{x}$ ：样本均值
- μ ：总体均值
- σ ：总体标准差（已知）
- n ：样本量

3. 查 p 值

根据 z 值在标准正态分布中找到 p 值。

4. 做结论

如果 $p < 0.05$ ，则拒绝 H_0 ，认为差异显著。

● 如何理解实验中的 P 值

P 值的作用：P 值可以帮助我们判断实验中的观察效果是否具有统计学意义，即一个指标的相对变化幅度是由于实验干预策略引起的，还是仅仅由于随机变异导致的

数理定义：在原假设为真的情况下，观察到的统计结果(或更极端结果)出现的概率

如何理解 P 值：我们常设定显著性水平为 0.05，如果 P 值<0.05，意味着我们有比较充足的理由认为这指标在这次实验中表现出来的相对差异是由策略改动带来的显著变化。根据相对变化幅度的正负可以得知策略的效果是好还是坏。P 值越小，更有信心认为是策略生效带来的结果

1.3 【检验假设正确性】

A/B 测试可能出现的结果假设检验会推断出两种结果:

- 接受零假设，拒绝备择假设，也就是说实验组和对照组的指标是相同的
- 接受备择假设，拒绝零假设，也就是说实验组和对照组的指标是不同的

！请注意，这两个结果只是假设检验根据样本数据，通过一系列统计计算推断出的结果，并不一定代表事实情况(总体数据情况)。如果考虑到事实情况的话，结合假设检验的推断结果会有四种可能:

	两组指标事实上不同	两组指标事实上相同
假设检验推断出两组指标不同	推断正确	第一类错误
假设检验推断出两组指标相同	第二类错误	推断正确

第一类错误 (Type I Error): 统计上的定义是拒绝了事实上是正确的零假设。在 A/B 测试中，零假设是两组的指标是相同的,当假设检验推断出两组指标不同,但事实上两组指标相同时，就是第一类错误。我们把两组指标不同称作阳性 (Positive)。所以，第一类错误又叫假阳性 (False Positive)

发生第一类错误的概率用 α 表示，也被称为显著水平 (Significance Level)。“显著”是指错误发生的概率大，统计上把发生率小于 5% 的事件称为小概率事件，代表这类事件在一次抽样中不容易发生。因此显著水平一般也为 5%

第二类错误 (Type II Error): 统计上的定义是接受了事实上是错误的零假设。在 A/B 测试中，当假设检验推断出两组指标相同，但事实上两组指标是不同时，就是第二类错误。我们把两组指标相同称作阴性 (Negative)，所以第二类错误又叫假阴性 (False Negative)

发生第二类错误的概率用 β 表示，统计上一般定义为 20%，而我们常说的统计功效就是 $1-\beta$

第一类错误的含义

第一类错误发生的概率用 α (alpha)表示，通常设定的显著性水平为 0.05，意味着有 5%的概率犯这种错误。通俗理解就是我们错误地认为某个效应或差异存在，而实际上并不存在

相当于说策略可能本身实际是没有什么价值的，但我们错误的以为它是有价值的。进而做出

错误的决断上线，那它的风险是比较大的，所以我们在设定第一类错误时、标准往往会定的比较低:5%，就是希望尽量避免这种错误的发生

第二类错误的含义

第二类错误发生的概率用 β (beta)表示。它其实更常提到的是对应的变体:统计功效(power) $1-\beta$,表示正确检测到效应的概率

也就是说如果策略本身实际是有价值的，那我们在做一次实验时，希望有 80% 的概率是通过这次实验的结果表现得到策略本身有价值这个结论，通常默认设定统计功效为 80%

如何理解这两类错误

在实际的统计检验中,我们通常希望最小化这两种错误的概率。然而它们之间存在权衡关系,在样本量不变的情况下,降低第一类错误的概率会增加第二类错误的概率,反之亦然
要想降低这两类错误出现的概率, **最朴实也最有用的式就是提升样本量**

2、A/B 实验最小样本量的确定和计算

为什么要算需要的样本量

如果实验的样本量很小,凭大家的直观感受就能判断这会存在问题,其原因是如果实验选取的样本量太小,那就很可能在一次实验中抽取的样本代表性较差,不太能代表真实水平。

举一个 Case: 我想知道全国人民的月收入水平均值,那从全国范围内随机抽 2 个人/1 万个人/10 万个人/1 亿个人分别计算得到的收入均值,很显然随机抽 1 亿个人计算的数据它的代表性会更强,而随机抽 2 个人得到的数据基本是不可用的。

在这我们很容易直观总结得到一个结论:样本量越大,其代表性越强,得到的结论也会更可靠。

样本量太小会有弊端,那样本量越大越好是不是就行?针对这一点,在不考虑成本,只从实验的角度来说确实是合理的,正如上面所说样本量越大,其代表性越强。

但实际情况是会有很多的其他因素是不可被忽略的,其中最重要的一点就是实验成本的问题:

问题一: 做实验是有风险的,应该将风险尽可能降为最低

做实验有新的改动出现时,是不可避免存在出现未知问题或 Bug 的可能性

实验的改动可能对线上用户体验是负向影响,在不确定对指标影响如何的情况下尽可能保持谨慎

开实验难免会带给用户反复变化的体验,这种情况应尽可能避免

问题二: 线上的策略迭代、功能改动可能是并行状态,同期可能会存在多个实验并行,同层实验应互斥,避免出现流量交叉造成数据污染

为了保证线上迭代的效率,合理高效的利用流量是提高数据决策的关键一环

因此考虑到实验成本的因素,样本量也不是无脑越大就越好,而应该是在满足实验测试需求的情况下尽可能小,也就有了实验最小样本量确定这个命题

2.1 计算最小样本量

公式：

$$n = \frac{(Z_{1-\alpha/2} + Z_{1-\beta})^2}{\left(\frac{\Delta}{\sigma_{\text{pooled}}}\right)^2} = \frac{(Z_{1-\alpha/2} + Z_{\text{power}})^2}{\left(\frac{\Delta}{\sigma_{\text{pooled}}}\right)^2} = \frac{\sigma_{\text{pooled}}^2}{\Delta^2} (Z_{1-\alpha/2} + Z_{\text{power}})^2 \approx \frac{15.69\sigma^2}{\Delta^2}$$

- n 代表最小样本量
- Δ 代表实验组和实验组评估指标的绝对差值大小
- σ_{pooled}^2 代表实验组和对照组的综合方差，实际中可以用用户指标的 2 倍的样本方差近似代替
- $Z_{(1-\alpha/2)}$ 和 Z_{power} 代表对应的 Z 分数，在确定了显著性水平 α 和统计功效 $1-\beta$ 后，这两个值为一个常数

例

通过查询过往每天抖音大盘投稿率数据可以知道大盘投稿率约在 9% 左右，同时过去做有关提升投稿率的实验经验可知一个有效的功能改动大约能相对提升该指标 +0.2%；那么就能根据最小样本量的公式计算得到相应的数据：

实验目标指标	当前指标水平大小	指标预期提升的最小相对幅度	指标预期提升的最小绝对幅度	指标方差	所需的最小样本量
抖音大盘投稿率	9%	0.20%	0.00018	8.19%	39,660,833

2.2 样本量影响因素与 n 的关系

从上面公式中我们能很明确的看到影响最小样本量的因素会有四个：

- **显著性水平 α** ：一般选定 α 水平为 0.05
- **统计功效 Power**：一般选定统计功效为 80%
- **Δ 大小**：即我们做这次实验预估对目标指标提升的绝对水平是多少
- **指标综合方差的大小**：指标综合方差 ≈ 2 倍的样本方差，那就是需要知道指标的方差大小是多少

这四个影响因素和样本量大小之间的关系：

【显著性水平 α 】

显著性水平 α 也叫做犯第一类错误的概率，显著性水平越小，在公式中分母的 Z-score 越大，计算得到的样本量也就越大；因此显著性水平 α 与样本量呈现的是反比关系。这点其实直观也很好理解，我们希望犯第一类错误的概率越小越好，那么就需要结果更加精确，进而需要更多的样本量进行实验观测

【统计功效 Power】

统计功效 $\text{Power} = 1 - \beta$ ，其中 β 也叫做犯第二类错误的概率，Power 要越大，那么 β 就是要越小。

因此可推导出统计功效 Power 和样本量呈现的是正比关系

【 Δ 大小】

由公式可知， Δ 大小和样本量大小呈现反比关系。 Δ 代表的是实验预估对目标指标提升的绝对水平，也就是实验组和对照组评估指标的绝对差值

可以这样直观理解这个因素：当我们想要观测到的差值越小，这是在实验中越难观测到的，因为实验本身抽样是存在抽样误差的，实验想要区别出抽样误差和策略本身较小的影响，那自然就需要更大的样本量去提升统计功效

【指标综合方差的大小】

由公式可知，指标综合方差的大小和样本量大小呈现正比关系。指标方差越大意味着指标的波动性越大，指标的波动范围就越广，那自然需要更多的样本量来进行实验

2.3 关于最小样本量问题

Q1：算出来的最小样本量是对照组+实验组总的数量吗

不是的，按上述公式计算得到的**最小样本量是实验组中一组的样本量大小**，如果实验有对照组和实验组两组的话，也就是对照组和实验组的量级均应该 $\geq$ 最小样本量

Q2：计算出来的最小样本量具体代指的是什么

计算得到的最小样本量本质是**实验的实验单元**，并且这是我们目标指标分母对应的实验单元。这一点认知是非常重要的，下面展开说一下这点如何理解

设想一下问题引出的那个实际业务案例，我们定下的目标指标是大盘投稿率这个指标，大盘投稿率的口径是=大盘投稿的人数/大盘活跃的人数。我们基于这个指标在假定了最小提升幅度下计算得到了我们的最小样本量，那这个时候我们的最小样本量的含义就是我们目标指标分母对应的实验单元，也就是实验进组的是大盘活跃用户，更直白的意思就是每个组应该有 3966w 的进组活跃人数

那如果这个实验，我们的改动是在拍摄器里面，也就是说如果用户没有进入拍摄器，那这个改动对于用户本身而言是没有任何影响的，那我们一个很朴素的想法是目标指标的投稿率口径应该是=大盘投稿人数/进入拍摄器的人数。那么我们基于这个指标也可以去计算对应的最小样本量，这个时候我们的最小样本量的含义就是我们目标指标分母对应的实验单元，也就是实验组进组的是大盘有进入过拍摄器的用户，更直白的意思就是每个组应该有 xx 量级的实验期间进入拍摄器的人数

3、A/B 实验实操常见问题及处理方法

在 AB 实验实操中，我们会常遇到两个东西：

其一：在计算最小样本量的时候有个参数：目标指标预期提升的最小幅度

其二：在实际实验跑了一段时间后我们常常会计算得到一个指标「**检验灵敏度**」，它用来判断在当前条件下能有效检出目标指标的 diff 幅度

在样本量计算中涉及到的参数「目标指标预期提升的最小幅度」，称之为目标指标预期提升值

在实验进行中，我们会计算一个指标：检验灵敏度，称之为 MDE

3.1 检验灵敏度(MDE)

在 AB 实验中，**检验灵敏度(MDE)**是指在给定的置信水平和统计功效下，实验能够检测到的最小的效应大小，它帮助我们理解实验是否有足够的能力去检测出实际的效果

3.2 检验灵敏度(MDE)的计算

一、双样本比例检验 (Proportions Test)

(例如：比较转化率、点击率是否显著不同)

公式：

$$MDE = (Z_{\alpha/2} + Z_{\beta}) \cdot \sqrt{\frac{2 \cdot p \cdot (1-p)}{n}}$$

参数说明：

- MDE : 最小可检测效应 (如转化率的绝对差异, 0.01 表示 1%)
- $Z_{\alpha/2}$: 显著性水平 Z 值 (例如 $\alpha = 0.05$ 时, $Z \approx 1.96$)
- Z_{β} : 统计功效 Z 值 (例如功效 $1 - \beta = 0.8$ 时, $Z \approx 0.84$)
- p : 基线比例 (如对照组的转化率)
- n : **每组**的样本量 (非总样本量)

3.3 如何使用检验灵敏度(MDE)

当我们实验运行了一段时间，此时目标指标不显著，那我们下结论：目标指标变化不显著。这个时候得到的结论是否 solid 呢？

这个时候我们就可以通过计算检验灵敏度 MDE 来帮助我们做这个决策。我们通过比较检验灵敏度 (MDE) 与目标指标的预期提升率来判断不显著的结论是否 solid，可以避免实验在灵敏度不足的情况下被过早作出非显著结论而结束，错失有潜力的 feature。

例：

把抖音拍摄页面中右下角相册功能的 icon 由相册图标改为用户相册的最新一张照片这个改动我预期对投稿率能提升 2%，那我对该指标的预期目标提升率为 2%，实验进行了一周：

如果此时 $MDE=1\%$ ， $MDE < \text{预期提升率 } 2\%$

这个时候说明如果这个改动是真实有正向作用的哪怕它对大盘投稿率仅有 1% 的提升，以我们当前的实验数据是足以能够检测得到的，而我预期提升是 2%，这个时候指标仍然不显著，

那说明这个 feature 改动应该是达不到预期的目的了，这个实验没有必要再等下去了，可以考虑如何进一步迭代该功能，或者结合业务其他信息、ROI 等维度进一步判断该 feature 是否值得上线

如果此时 MDE 是 3%， $MDE > \text{预期提升率 } 2\%$ ，这个时候说明当前的实验数据能检测出来的显著性最小差异值是 3%，实验整体的灵敏度还不太够，如果这个改动是真实有正向作用的且真实能提升投稿率 2%，那由于灵敏度不够，当前该指标会呈现出不显著的结果。但这种情况下指标是有变显著的可能性的，此时分析师的建议就可以考虑持续再观测一下，或者建议扩大流量

3.4 提升实验显著性的方法

回到上面提到的检验灵敏度的公式上，我们发现影响 MDE 的参数有三个，一个是显著性水平 α ，一个是指标的方差，然后是样本量。

我们想要提高实验的检验灵敏度，也就是要让 MDE 的值尽可能变小，那从公式上来看，我们能主要做的就是让标准差变小 or 让样本量增加

目标之一：降低标准差/方差

在日常工作中，这是一个非常通用的解决方案，在降低方差的方法选择方面，我们常用的处理会有以下三种方法：

● 剔除极端值

我们可以通过对样本中一些极端值进行剔除，比如在计算抖音人均使用时长这个指标时，可以将对照组和实验组的使用时长头部 1% 的用户给去除掉，往往会看到这样操作后指标的方差会有数量级的下降，对指标检验的灵敏度会有非常大的提升。

这个方法在一些直播业务、游戏业务中会特别有效，因为这些业务的分布往往都是二八分布，头部非常少部分人群对指标的贡献是非常大的，往往这少部分人分流在对照组还是实验组就会对实验结果造成较大的影响，影响决策和判断

● 改变分析的人群

像上述我们提到的把抖音拍摄页面中右下角相册功能的 icon 由相册图标 改为 用户相册的最新一张照片 这个实验，我们实验的进组人群可能就是大盘的活跃用户，但这个功能的触发是用户至少得进入到抖音拍摄器以后，如果用户都未进入拍摄器，那这个功能的改动不会对他们造成任何影响

所以我们这个时候可以考虑将目标指标由大盘投稿率（投稿人数/Dau）调整为投稿率（投稿人数/进入拍摄器的人数）。我们显然能够看到这两者的差异点在于大盘活跃用户拍摄器的渗透率是多少，如果大盘活跃用户拍摄器渗透率非常高，即进入拍摄器的人数甚至能近似约等于 Dau，那这个时候改变分析的人群意义不大，但如果某个 feature 的渗透率是很低的，这个时候去改变分析的人群，对指标的均值水平和方差均会有非常大的改变，一定程度上也

是能起到降低指标方差的目的

这个方法主要会在一些渗透率偏低的功能做实验时重点考虑

● 选择比率类的指标

这点也非常好理解，比如在游戏中有付费率指标和 Arpu（人均充值金额）指标，显然付费率这种比率类指标的方差是远远小于 Arpu 这种均值类指标，因为一个大 R 用户他可以贡献很高的金额，造成 Arpu 的方差很大，但在付费率指标上来说，大 R 也是贡献分子+1，充 1 块钱的用户也是贡献分子+1

这个方法是有许多的适用场景的，比如我游戏在付费活动上做了一个加大对充值 Top3 的奖励，很明显这个改动核心撬动的是头部大 R 用户，这个时候我们去关注付费率、关注 Arpu 反而可能会比较失真，在这种情况下小伙伴们可能容易想到的是我们去关注大 R 用户群体的人均充值或者付费率

这当然是一种好的方法，但大 R 用户群体本身个人的差异也非常大，自然方差也大。这个时候我们可以选择一些像充值 ≥ 1000 的人数占比、充值 ≥ 10000 的人数占比等比率类指标，效果可能会更好

目标之二：扩大样本量

扩大样本量这个目标应该说非常容易理解，理论上只要样本量足够大，两组之间肯定会有显著的差异，一个非常直观的理解是世界上不可能有和你一模一样的人。有可能有和你长相非常相似的人，习惯非常相似的人，但不可能跟你一模一样的人，即使跟你再相似，你们两之间都肯定有着显著的差异

所以扩大样本量是能提升指标的检验灵敏度，实际工作中我们常用的扩大样本量的方法有两个：

● 延长测试时间

因为我们实验的流量比例往往是设置为大盘活跃人数的 xx% 比例，随着时间的延长，会有更多的活跃用户进组，自然能提升样本量

但这种方法相对来说时间成本比较高

● 扩大测试使用流量

这个方法就好理解，之前实验可能是 30% 的流量，直接把实验流量扩大到 50%，能立马有大量的用户进组，扩量非常快

这种方法好处就是时间成本低，但也有潜在的风险，比如之前解释的实验并非流量越大越好

● 注意 Pre-AA 的变化

其实很多时候，我们是非常需要去关注 Pre-AA 的情况，也就是两组用户在进组前的数据表现情况，比如有可能因为分流不均，实验组相较于对照组在进组之前就有了较大的负向显著，而在实验后这个指标变成了不显著，没有太大差异。那这个时候大概率可能这个 feature 是有价值的，但由于分流带来的抽样误差把功能的真实价值给掩盖掉了

4、AB 实验流程

以一个实际的业务场景去描述 AB 实验流程

A/B 实验的运行大致可以分为六步：

1、明确业务问题和实验目的

这一步核心了解基础信息，包括：业务的背景、优化内容的大致规划、预期优化的目标和本次实验改动点的关联性和业务逻辑

站在分析师更加专业的角度去判断是否有实验的必要、这个实验的预期设定

2、给出实验方案

在清楚业务问题和实验目的后，分析师要给出具体的实验方案并和业务对齐达成一致。包括：明确实验人群、实验流量层、实验流量大小、分流的方式、实验时长、实验评估的关键指标组和护栏指标组等

3、实验上线后，检测策略是否如预期生效

把自己当作实验的 owner，当实验上线后要检测-下策略是否如预期生效。一般采用测试机验证策略生效+数据验证进组人数、人群结构、Pre-AA、策略是否符合预期生效等

确保实验如预期策略生效、按自己的实验方案正常进行

4、搭建实验看板或报表，不定时观测数据趋势

搭建实验核心指标看板并分享给业务相关方，不定时观测数据趋势，对实验数据表现做到心中有数

5、满足观测周期后回收数据进行分析

在做分析时，不要只在数据层面上去做事情，要多思考数据的结果是否有对应的业务逻辑链路，这条链路的数是否能够相互验证，走得通

6、根据分析结论明确后续 To Do，是否达到上线标准 or 需要进一步迭代 且 有什么迭代的建议

看完了数据要给出分析师的建议时，一定要尝试代入业务的视角，思考自己给出的建议是否有落地性，每一条建议是否有对应的数据结果的支撑和对应的业务逻辑成立

三、倾向得分匹配 PSM 和双重差分 DID

PSM 作用：找出两组相似的个体或单位，一组接受了政策或干预，另一组没有。这样可以排除其他因素的影响，只看政策或干预本身的效果。（找个长得像的）

DID 作用：比较两组在政策或干预前后的变化，看看接受了政策或干预的一组是否比没有接受的一组有更好的结果。这样可以排除时间上的影响，只看策略或干预带来的变化

PSM-DID 模型的目标是估计策略或干预对接受了它们的一组（处理组）相比没有接受它们的一组（控制组）有多大的影响，这个影响就叫做平均处理效应（ATT）。

应用：

PSM-DID 模型通过 PSM 方法间接帮我们选出另一个“平行世界”中的用户群，再通过 DID 方法帮助我们估算如果用户没有 xxx，xxx 会平均提升多少，从而得出策略对结果的干预效应

1、模型原理

PSM-DID 模型实质是将 PSM 和 DID 结合起来，先用 PSM 进行匹配，再用 DID 进行回归计算干预带来的因果效应

$$\begin{aligned} ATT &= E(y_{1i}|D_i = 1) - E(y_{0i}|D_i = 1) \\ &= E(y_{1i}|D_i = 1) - E(y_{0i}|D_i = 0, P(X)) \\ &= [E(y_{1i}|D_i = 1, T = 1) - E(y_{0i}|D_i = 0, T = 1, P(X))] \\ &\quad - [E(y_{1i}|D_i = 1, T = 0) - E(y_{0i}|D_i = 0, T = 0, P(X))] \end{aligned}$$

其中，

- y_{1i} 和 y_{0i} 分别表示个体 i 在接受和未接受处理时的潜在结果变量；
- D_i 表示个体 i 是否接受处理，取值为0或1；
- T 表示时间，取值为0或1；
- $P(X)$ 表示倾向得分函数，是一个关于可观测协变量 X 的函数；
- $E(\cdot)$ 表示条件期望。

公式中：

第一行表示 ATT（治疗对接受治疗者的平均治疗效果）的定义；

第二行表示在给定倾向得分后，控制组可以作为处理组的有效对照；

第三行表示在给定倾向得分后，利用前后两个时间点上结果变量的差异来估计 ATT

2、建模过程

● 第一步，明确问题，确定假设

确定研究对象、研究问题、研究假设和研究方法。明确要评估哪种政策或干预对哪些个体或单位有什么样的影响，并选择合适的数据来源、样本范围、时间跨度、结果变量和协变量

● 第二步：数据获取、清洗

基于第一步确认好需要获取的变量后，进行数据的获取与清洗、整理、描述和可视化，检查数据质量、数据特征、数据分布等

● 第三步：计算倾向得分，基于得分进行样本匹配

根据协变量估计每个个体接受处理的概率（即倾向得分），得分通常用一个二元回归模型来估计，如逻辑回归、Probit 回归。其数学式为： $P(D_i=1|X_i)=f(X_i, \beta)$ （其中， D_i 是个体 i 的处理变量， X_i 是个体 i 的协变量向量， β 是待估参数向量， $f(\cdot)$ 是一个逻辑函数或者正

态分布函数),选择合适的匹配方法、匹配算法、匹配范围等进行匹配。[匹配后检验匹配质量,包括平衡性检验、共同支撑区检验](#)等。

● 第四步: 双重差分回归

利用匹配后的数据构建双重差分回归模型,选择合适的回归方法、回归函数、回归控制等进行回归,估算平均处理效应。[回归后要检验回归效果,包括显著性检验、平行趋势检验、稳健性检验](#)等。

● 第五步: 评价结果, 给出建议

根据回归结果估算策略或干预对处理组相对于控制组的平均处理效应 ATT, 并与研究假设进行比较和分析。讨论结果可能存在的局限性、不确定性、偏误等, 并提出改进方向或政策建议。

3、模型优点与局限性

【优点】

① [实施简易](#), 相较于随机实验 (ABTest) 方法, PSM-DID 方法不需要进行随机分配处理组和控制组, 而是利用已有的观察数据来估计因果效应。这样可以避免一些伦理、成本、可行性等方面的问题(比如, 在电商领域, 我们可能无法随机地给用户发放不同金额的红包, 因为这可能会影响用户的满意度或忠诚度)

② [灵活运用](#), 根据数据特征和业务场景的不同, 可以灵活地选择匹配方法、匹配算法、匹配范围等参数, 进行模型调整

③ [可信准确](#), 通过 PSM 与 DID 方法的有机结合, 同时解决可观测变量和不可观测变量带来的选择偏差问题, 提高政策效应估计的准确性和可信度

④ [实现简单](#), 业界已有多个成熟因果方法库可直接应用实现模型, 如 Ylearn、psmy 等

【局限性】

⑤ [前置条件难检验](#), [PSM-DID 方法需要满足条件独立性假设 \(CIA\) 和平行趋势假设 \(PTA\)](#), 这两个假设都是无法直接检验的, 只能通过一些间接的方法来验证。

⑥ [小样本难应用](#), PSM-DID 方法需要有足够大的样本量来进行倾向得分匹配, 否则可能存在匹配不足或匹配不平衡的问题

⑦ [变量少难实施](#), PSM-DID 方法需要有足够多的协变量来估计倾向得分, 否则可能存在遗漏变量偏误

4、案例

以知识付费场景为例, 通过研究用户参加知识星球后今年可以提升多少收入?

【DID】

(假设) 同一家公司小王和小明, 没参加星球前小王、小明收入随时间变化是一样的, 小王去年从每个月 5000 涨到每个月 5500, 小明从每个月 5100 涨到每个月 5600 ([时间变化趋势一致, 都每个月涨了 500](#))

后来小王加入了知识星球, 今年从每个月 5500 涨到了每个月 6500 每个月涨了 1000, 小明没有参加今年从每个月 5600 涨到每个月 6100, 每个月涨了 500

——» 那么我们可以认为参加星球当年帮助用户小王多涨 500 (1000 (时间效应和星球效应叠加) -500 (时间效应)) 这就是 DID 方法。

【PSM】

通过 HR 总结的经验来看，比如最影响用户收入因素主要是用户的年龄、性别和学历，参加星球的小王年龄为 24，学历本科、性别男，我们可以发现公司里没有参加星球的小林刚好也是年龄 25，本科男和小王在这几个因素上最为相近，可以看到小王今年每个月涨了 1000，而小林今年每个月涨了 800，那么我们可以认为**参加星球当年可帮助用户小王每月涨 200**（1000（其他可观察的影响效应和星球效应叠加）-800（其他可观察的影响效应）），这就是匹配的思想方法。

更进一步为了更好总结可观察的影响效应，我们用一个二分类模型可以训练每个人参加星球的意愿概率 P，用 P 来表示用户得分，得分越相近，用户越相近，于是通过模型预测我们得到小王这类人参与的概率是 0.67，与公司的为参与星球小谢（0.65）最为相近，小王今年每月涨了 1000，小谢每月涨了 600，于是可以认为**参加星球当年可帮助用户小王每月涨 400**(1000（其他可观察的影响效应和星球效应叠加）-600（其他可观察的影响效应）），这就是倾向性匹配 PSM 的思想方法

PSM-DID 方法结合两种思想：

先用 PSM 方法找到和小王最相近的小林和小谢，再选出和小王参加星球前（参加前每年涨 500，参加后当年涨 1000）收入变化最近的小林（参加前时间每年涨 500，没参加后当年涨了 800）

那么我们可以认为**参加星球当年可帮助用户小王每月涨 200**（1000（可观察的影响效应、时间效应和星球效应叠加）-800（可观察的影响效应、时间内生效应叠加））

四、因果推断可靠性检验方法

目的：确保因果推断结论的可靠性



这几种方式的目的、必要性与优势：

检验类型	目的	必要性	优势
模型完备性检验	确保倾向得分模型的准确性	防止模型偏差，提高匹配质量	早期识别并修正模型问题
样本平衡性检验	验证处理组与对照组的协变量相似性	保证两组可比，支持有效因果推断	显示匹配效果，验证策略有效性
结果稳健性检验	检验结论对不同方法和样本选择的敏感性	确保结论的健壮性，不依赖特定方法	提高研究透明度和信任度，验证结论的广泛适用性

1、模型完备性检验-AUC 值

1.1 概念：

AUC 值可以理解为一个评估分类模型完备性的参数，范围从 0~1

当这个值越高的时候模型就越可信。它可以直接运用于判断分类、预测模型的效果


举一个好理解的例子，当医生想要设定一个阈值，来检测糖尿病的血糖检测是否合理时，可以通过不同的血糖值设计实验，最终通过 AUC 判断哪个实验的结果具有最好的诊断能力，最终区分出患病和未患病的糖尿病患者。

同样的，在我 PSM 模型中，通过计算倾向性得分（协变量）构建了一个简单的预测模型，用来判断两件事情的因果性（比如用户加入星球后，收入是否有提升？）。此时 AUC 值就可以作为一个佐证，如果 AUC 值较低，则需要重新考虑模型的协变量选择或匹配策略。

在倾向性评分匹配 (PSM) 中，倾向得分预测模型一般使用 AUC 值 (Area Under the Curve) 进行：

- **模型评估：** AUC 值可以帮助评估倾向性评分模型的预测性能，特别是模型是否能有效区分是否接受干预的个体。高 AUC 值表明模型具有较好的区分能力。
- **模型优化：** 通过 AUC 值，研究者可以识别并调整模型，改进特征选择或参数设置，以提高模型的整体性能
- **诊断工具：** AUC 可以作为一种诊断工具来辅助评估倾向性评分模型的质量。如果 AUC 值异常低，则可能表明模型未能捕捉到影响个体接受治疗概率的关键协变量
- **在倾向性评分匹配 (PSM) 或其他预测模型中，AUC 值的范围从 0 到 1，值越高表示模型的区分能力越好。以下是 AUC 值的一般解释，一般任务 AUC 值>0.7 模型的预测较为可信，** 明细参考规范如下：

- ◆ **0.5:** AUC 值为 0.5 意味着模型没有预测能力，等同于随机猜测。在实际应用中，这表明模型并未捕捉到数据中的任何有效模式。
- ◆ **0.6 - 0.7:** 这被认为是较低的预测能力。虽然模型具有一定的区分能力，但效果并不理想。
- ◆ **0.7 - 0.8:** 这通常被视为一个可接受的区分能力。模型在此范围表现出较好的预测效果，可以用于实际应用，但仍有改进空间。
- ◆ **0.8 - 0.9:** 这被认为是很好的预测能力。模型在这一范围内通常能提供较为准确的预测。
- ◆ **0.9 以上:** 非常出色的预测能力，模型能极为准确地进行分类



上图展示了使用逻辑回归模型在合成数据集上绘制的 ROC 曲线（虚拟数据）。图中的曲线

(橙色)表示模型的性能,与对角虚线(深蓝色)比较可以看出模型的效果。ROC 曲线下的面积 (AUC) 为 0.92,这表明模型具有较高的区分正负类别的能力

ROC 曲线含义简介:

横坐标 (FPR): 负正类率,预测为正实际为负的样本中占实际为负样本的比例,FPR 越大负样本被判断为正样本的比例越大

纵坐标 (TPR): 真正类率,预测为正实际为正的样本中占实际为正样本的比例,TPR 越大,正样本中判断为正的的比例越大

1.2 AUC 不符预期 常用归因视角与优化方法

PSM 建模过程,AUC 值低主要的归因的方向:

- **协变量选择不全:** 如果选用的协变量不能充分解释处理组和对照组之间的差异,模型可能无法准确预测倾向性评分,从而导致模型的 AUC 较低,需要结合业务经验 增加或优化协变量,重新审视并可能扩展协变量的选择,确保包括所有关键的预测变量。

更细节的原因可能包括:

- **用户行为的多样性:** 用户领取优惠券和消费行为可能受到多种因素的影响,如用户的收入水平、消费习惯、消费能力、历史购买记录等。如果这些变量中的一部分未被纳入模型,那么倾向得分可能无法准确反映不同用户接受优惠券的概率。
- **时间因素和外部环境:** 模型中未考虑的时间相关因素(如是否节假日、是否促销周期等)和外部环境变量(如经济状况、竞争对手行为)也可能对消费行为产生显著影响。例如,节假日促销可能本身就会提高用户的消费水平,而不仅仅是因为优惠券的效果。这需要我们关注实验发生的时间。

其他原因可能包括:

- **数据不平衡:** 如果处理组和对照组的样本量差异很大,或者某一组的数据量太少,也可能影响倾向性评分的准确性和 AUC 值。不平衡的数据可能导致模型过度拟合或在小的组中预测能力不足
- **数据预处理不当:** 数据中的噪声过高、缺失值多或存在错误的输入,都可能影响模型的学习能力和预测准确性,从而导致 AUC 值低
- **模型选型不当:** 如果使用的统计模型(如逻辑回归)不适合数据的实际分布或关系,或者模型过于简单而无法捕捉复杂的非线性关系,也可能导致预测能力弱,AUC 值低
- **存在未观测的混杂变量:** 如果模型中未包括重要的混杂变量,即那些同时影响处理分配和结果的变量,这将导致倾向性评分估计不准确,影响整个模型的预测性能
- **样本量不足:** 对于倾向得分模型,尤其是在数据集中的事件(如治疗或转换)较少时,较小的样本量可能不足以提供足够的统计功效来检测组间的真实差异。这种情况下可能需要增加样本量或使用数据增强技术。

2、匹配组的平衡性检验（共同支撑分析、标准化偏差分析）

2.1 平衡性检验的目的和原理

在使用倾向得分匹配（PSM）模型时，进行匹配组的平衡性检验是非常关键的步骤。

【平衡性检验目的】

这一过程确保了处理组和对照组在匹配后在观察到的协变量上是相似的，从而可以更有效地评估处理效果（如干预措施或政策变动等）对结果变量的影响。

PSM 通过倾向分匹配的方式，从控制组匹配出一组与干预组在出干预变量外的关键特征都相似一样的样本组作为控制组进行对比，那么对于匹配结果我们从数据侧需要回答证明点在于：

匹配组是否具有代表性：是不是每个控制组样本都有匹配到对应样本来对比

匹配组是否具有可比性：匹配组是否真的很好的消除与干预组在关键特征上的差异

【平衡性检验原理】

上述两个需要证明的点，本文分别介绍一种常用的方法用于证明匹配结果在这两方面可靠性


——**共同支撑分析：**通过可视化图形的方式，检查处理组和对照组的倾向得分是否具有重叠的数值范围。如果两组的倾向得分数据没有重叠，意味着在一组中存在的观察值在另一组中不存在，这可能会导致对这两组进行比较时的偏差，反之，则可证明匹配组结果样本具有代表性

- **标准：**通过对比匹配组、干预组间的特征的各个特征的组偏差，量化特征组间差异，证明匹配组关键特征分布与干预组无差异

2.2 平衡性检验方法实现&结果解读

共同支撑分析：核心在于将处理组与对照组倾向得分可视化，直观观察重叠部分即可，以常用的箱线图方法为例

- **实现方法：**通过绘制处理组和对照组的倾向得分箱线图来进行共同支撑分析
- **结果解读：**解读偏专家经验，核心看处理组和对照组的箱线图是否显示出重叠的箱体和箱线，意味着两组的倾向得分数据在中间较大范围的重叠，这表示共同支撑区域存在，认为两组数据是可以进行有效比较的。如果箱线图显示出明显的不重叠，则表明数据之间缺乏共同支撑，可能需要重新考虑匹配策略或数据选择



标准化偏差分析：是在倾向得分匹配（PSM）建模中用于评估匹配后处理组和对照组之间平

衡性的一种方法。它旨在检查处理组和对照组在各个特征上的差异是否得到了有效的平衡，实现流程如下：

处理组和对照组关键特征的标准化偏差计算，计算公式为：

$$\frac{\bar{X}_{\text{treatment}} - \bar{X}_{\text{control}}}{\sqrt{\frac{s_{\text{treatment}}^2 + s_{\text{control}}^2}{2}}}$$

$\bar{X}_{\text{treatment}}$ 和 $\bar{X}_{\text{control}}$ 分别是处理组和对照组在某一观测变量（X）上的均值；

$s_{\text{treatment}}^2$ 和 s_{control}^2 分别是处理组和对照组在该观测变量上的方差

2.3 平衡性检验结果不符预期如何优化

当PSM（倾向得分匹配）模型在进行平衡性检验（如标准化偏差分析和共同支撑分析）后结果不符合预期时，一般考虑通常从以下几个角度进行归因和优化：

- **样本选取问题：**样本量不足或样本选择偏差，都会导致匹配可靠性结果不理想，一般通过增加样本量或进行数据收集的优化，以确保样本具有代表性并能够覆盖足够的倾向得分范围
- **协变量选择问题：**关键协变量考虑不全，匹配样本仍受到混杂因素影响，倾向得分可能无法有效地平衡这些未观察到的差异，需要结合业务经验，或对比原有的特征库，重新评估并扩充模型中的变量，确保包括所有已知的和可疑的混杂变量，消除混杂因素的影响
- **匹配方法不恰当：**匹配策略不恰当或过于简单 如 1:1 匹配、最近邻匹配，导致匹配无法有效平衡处理组和对照组的协变量，尝试使用更复杂的匹配算法，如倾向得分的核匹配、卡尺匹配或 1 对多匹配，提高匹配的质量
- **倾向分模型预测性能不佳：**用于生成倾向得分的统计模型可能未能准确估计每个个体接受处理的概率，模型对干预、结果的预测解读能力不佳，一般需要事先对倾向得分模型进行诊断测试，如 ROC 曲线分析，来评估模型的预测性能，尝试换用如随机森林或梯度提升机提升模型的预测性能

3、匹配结果的稳健性检验（反驳性检验、敏感性分析）

3.1 反驳性检验

【反驳性检验目的】：

一般通过加入随机变量作为混杂特征或干预变量、修改样本范围的方式检验匹配对比得到的估计因果效应的稳定性与泛化能力

【反驳性检验实现方法】：

- **安慰剂检验：**通过将处理组和对照组的标签打乱，然后进行匹配，如果匹配后的差异仍然存在，说明匹配可能没有起到作用。处理思想和 pre-a/a 类似，主要通过引入一组随机变量作为干预变量的方式检验样本特征选取和样本量选择是否存在问题
- **随机混杂检验：**添加随机的混杂因子（控制特征），因果效应变化较小，则表明 PSM 结果较为稳健
- **数据子集检验：**通过在多个数据子集上重复匹配并分析因果效应的稳定性

【反驳检验结果不符预期如何优化】

反驳结果不符合预期时，主要从特征选取优化、样本量两个角度进行优化

- 增加未考虑到的变量消除混杂因素影响
- 通过重采样或加权采样的方式，保证特征处理组和对照组的特征差异在可接受的范围

3.2 敏感性分析（基于 gamma 为例）

Gamma 敏感度分析通常基于模拟方法进行的，通过重复计算不同容忍度参数值下的匹配结果，并计算对应的 Gamma 值以及 P-value 的上限，来评估模型对于容忍度参数的敏感程度具体步骤如下：

- 计算不同容忍度参数值下的匹配结果。
- 对于每个容忍度参数值，计算对应的 P-value 的上限。
- 找到 P-value 上限跨过 0.05 对应的 Gamma 最小值。

一般使用 Gamma 是否大于 1.25 作为经验分界线，来评估匹配结果于容忍度参数的敏感程度

如果 Gamma 最小值大于等于 1.25，说明模型对于容忍度参数的敏感程度较低，匹配结果相对稳定

如果 Gamma 最小值小于 1.25，说明模型对于容忍度参数的敏感程度较高，匹配结果可能会受到参数设置的影响而发生较大变化

4、总结

主要介绍了在模型、匹配过程和匹配结果三个阶段，如何通过一系列可靠性检验方法来评估 PSM 因果推断结论的可靠性。

具体包括：

- **模型的 AUC-ROC 评价**，确保匹配得分的稳健性，模型角度上确保协变量选择的可行性
- **平衡性检验**：确保在 PSM 之后，处理组与对照组在观测特征上没有显著差异。
- **稳定性检验**：确保 PSM 模型对参数选择的鲁棒性，避免模型的不稳定性导致结论的不一致。
- **敏感性分析**：评估未观测因素对研究结果的潜在影响，确定模型的稳定性，增强对 PSM 结论的信心。

五、异动分析（果到因）

1、进行异动分析的原因

- **洞察业务健康度**：异常的波动（无论是正向还是负向）往往是业务某个环节出现问题或出现亮点的信号。及时发现并分析，有助于把握业务脉搏。
- **驱动业务决策**：理解异动原因和贡献度，是制定有效行动方案的基础。例如，发现 GMV

下降主要是由某核心城市用户流失导致,就可以针对性在该城市加强运营或修复产品问题。

- 评估策略效果: 当上线新功能、进行营销活动或调整价格策略后,数据往往会产生波动。异动分析能帮助判断这些策略的真实效果,区分是策略本身的作用还是其他外部因素干扰。
- 总结: 异动分析是连接数据波动与业务行动的关键桥梁。

2、异动分析的场景

异动分析的应用场景极其广泛,几乎覆盖所有业务领域:

1. **核心业务指标监控:** 用户指标: DAU/MAU 突然下跌或上涨? 新用户注册量激增? 老用户留存率波动?

- a. 交易指标: GMV、订单量、客单价为何偏离预期? 退款率异常升高?
- b. 流量指标: 网站/App 访问量骤降? 某个渠道的流量来源占比发生显著变化?
- c. 财务指标: 收入、成本、利润率出现预期外的波动。


2. **产品功能迭代评估:** 新版本上线后,关键功能使用率是否达到预期? 有无引起负面体验(如崩溃率上升)?

- a. A/B 测试中,实验组和对照组的核心指标差异是否显著? 各子指标如何贡献?
- 3. 市场营销活动复盘: 活动期间 GMV 暴增,是活动本身带来的增量,还是自然增长或其他因素? 各渠道(如微信、抖音、线下)的贡献如何?
- a. 活动 ROI 是否达标? 成本超支或节省的原因是什么?

3、核心武器: 贡献度的计算

找到异动方向后,最关键的一步是量化各个潜在因素的贡献度(Contribution)。这回答了“哪个因素影响最大?”和“每个因素具体影响了多少?”的问题。

以下是三种基础且常用的方法:



3.1 方法一: 加法型贡献度计算 (Additive Contribution)

● **核心理想:** 假设整体指标的变化量 (ΔTotal) 等于各个组成部分变化量 (ΔPart) 的直接相加。

● **公式:** $\Delta\text{Total} = \Delta\text{Part1} + \Delta\text{Part2} + \dots + \Delta\text{PartN}$

贡献度_{PartX} = $\Delta\text{PartX} / |\Delta\text{Total}| * 100\%$

- ΔTotal : 整体指标的变化量 (本期值 - 上期值/预期值)
- ΔPartX : 第 X 个组成部分的变化量
- $|\Delta\text{Total}|$: 整体变化量的绝对值 (用于计算百分比贡献)

● **适用场景:** 整体指标是各个组成部分的简单加和。

最常见例子:

○ 总销售额(GMV) = 品类 A 销售额 + 品类 B 销售额 + ... + 品类 N 销售额。

- 总用户数 = 新用户数 + 老用户数。
- 总成本 = 人力成本 + 服务器成本 + 营销成本 + ...

● 案例演示：

背景： 某电商平台，昨日总 GMV (Total GMV) 为 1200 万，相比前日 (1000 万) 增长了 200 万 ($\Delta\text{Total} = +200$ 万) 。

品类	前日 GMV (万)	昨日 GMV (万)	增长量 (Δ , 万)	贡献度 (%)	增长率 (%)
品类 A	400	500	100	50%	25.0%
品类 B	300	360	60	30%	20.0%
品类 C	300	340	40	20%	13.3%
总计	1000	1200	200	100%	20.0%

GMV 由三个品类构成：

- 品类 A：前日 400 万，昨日 500 万 ($\Delta A = +100$ 万)
- 品类 B：前日 300 万，昨日 360 万 ($\Delta B = +60$ 万)
- 品类 C：前日 300 万，昨日 340 万 ($\Delta C = +40$ 万)

计算贡献度：贡献度_A = 100 万 / |200 万| * 100% = 50%

● 贡献度_B = 60 万 / |200 万| * 100% = 30%

● 贡献度_C = 40 万 / |200 万| * 100% = 20%

● 结论： GMV 增长 200 万，其中品类 A 贡献了 50% (100 万) ， 品类 B 贡献了 30% (60 万) ， 品类 C 贡献了 20% (40 万) 。品类 A 是增长的主要驱动力。

优点： 计算简单，直观易懂。

缺点： 只适用于严格满足加法关系的指标。无法处理乘法关系（如转化率）或更复杂的结构。

3.2 方法二：乘法型贡献分解 (Multiplicative Decomposition - Log Transformation)

● 核心理想： 适用于整体指标 Y 是多个影响因素 X1, X2, ..., Xn 的乘积关系。即 $Y = X1 * X2 * ... * Xn$ 。常见的比率指标分解常采用此方法（通过取对数转化为加法）。

● 计算原理（核心：对数变换法）

○ 对目标指标 Y 及各影响因素 {X1, X2, ..., Xn} 执行自然对数变换： $\ln(Y) = \ln(X_1) + \ln(X_2) + ... + \ln(X_n)$

○ 计算对数层面的总体变动量： $\Delta \ln(Y) = \ln(Y_{\text{当期}}) - \ln(Y_{\text{基期}})$

○ 计算各因素的对数变动量： $\Delta \ln(X_i) = \ln(X_{i_当期}) - \ln(X_{i_基期})$

○ 计算各因素的对数绝对贡献值：贡献值_{lni} = $\Delta \ln(X_i)$

○ 因子贡献度 = $[\ln(\text{当期值}) - \ln(\text{基期值})] / [\ln(\text{总指标当期}) - \ln(\text{总指标基期})]$

● 案例演示（访问量分解）

访问量 = 活跃用户 × 功能渗透率 × 人均访问次数

因子	基期	当期	计算过程	贡献度
活跃用户	10,000	9,500	$\ln(9500/10000) = \ln(0.95) \approx -0.051$	27%
功能渗透率	70%	65%	$\ln(65/70) = \ln(0.929) \approx -0.074$	39%
人均访问次数	3.2	3.0	$\ln(3.0/3.2) = \ln(0.938) \approx -0.064$	34%
总访问量	22,400	18,525	$\ln(18525/22400) \approx -0.1899$	100%

渗透率下降是主因（贡献 39%），建议检查：

- 功能入口是否被调整
- 新版本是否存在 BUG
- 竞品是否推出替代功能*

- 优点：能有效处理比率型指标的分解问题，解决了加法模型不适用的情况。
- 缺点：计算稍复杂，结果是近似值（尤其当变化较大时误差会增大），要求因素间是乘积关系且不能有零值（ $\ln(0)$ 无定义）。

3.3 方法三：综合贡献计算法

- 核心思想：当影响因素之间存在复杂的交互作用，或者指标结构不是简单的加法或乘法（可能是混合或更复杂公式），或者需要更公平地分配多个因素共同作用产生的“协同”影响时，加法型和乘法型方法可能不够准确或公平。
- 核心：分母结构变化（如低质量用户涌入）和分子自身变化（如运营策略生效）会同时影响结果，须分离计算。
- 典型场景

场景	业务问题	常见误判
用户转化率下降	新用户占比大幅上升	“所有群体转化率都提升，为何大盘下降？”
平均客单价降低	低价商品销量占比增加	“每个品类客单价都增长，为何均值下跌？”
留存率异常波动	不同活跃度用户结构变化	忽略分母群体权重迁移的影响

● 案例演示

为什么 7 月大盘的完成度在下降，是结构性变化还是自身影响？

用户类型	6 月占比(S_0)	6 月完成率(I_0)	7 月占比(S_1)	7 月完成率(I_1)
新用户	20%	45%	35%	48%
活跃用户	50%	75%	40%	78%
回流用户	15%	35%	12%	40%
沉睡用户	15%	20%	13%	25%
大盘	100%	62.0%	100%	56.8%

- Step 1：计算总变化量
 $\Delta Y = Y_1 - Y_0 = 56.8\% - 62.0\% = -5.2\%$
- Step 2：计算指标效应（群体自身影响）

指标效应 = $\sum (I_{i1} - I_{i0}) \times S_{i0}$

用户类型	计算过程	业务含义
新用户	$(48\%-45\%) \times 20\% = +0.6\%$	新用户完成率提升 3%对大盘影响+0.6%
活跃用户	$(78\%-75\%) \times 50\% = +1.5\%$	活跃用户完成率提升 3%对大盘影响+1.5%
回流用户	$(40\%-35\%) \times 15\% = +0.75\%$	回流用户完成率提升 5%对大盘影响+0.75%
沉睡用户	$(25\%-20\%) \times 15\% = +0.75\%$	沉睡用户完成率提升 5%对大盘影响+0.75%
合计	+3.6%	所有群体自身进步带来增益对大盘影响+3.6%

○ Step 3: 计算结构效应（用户结构变化）

用户类型	计算过程	业务含义
新用户	$(35\%-20\%) \times 48\% = +7.2\%$	新用户占比增加对大盘影响+7.2%
活跃用户	$(40\%-50\%) \times 78\% = -7.8\%$	高价值用户流失对大盘影响-7.8%
回流用户	$(12\%-15\%) \times 40\% = -1.2\%$	回流用户减少对大盘影响-1.2%
沉睡用户	$(13\%-15\%) \times 25\% = -0.5\%$	沉睡用户减少对大盘影响-0.5%
合计	-8.3%	用户结构劣化导致对大盘-8.3%

○ Step 4: 验证闭合性

总变化 = 指标效应 + 结构效应
 $-5.2\% = (+3.6\%) + (-8.3\%)$
 误差 = 0.1% （计算四舍五入导致）

3.4 总结

三种方法有不同的使用场景，具体使用如下：

指标特征	首选方法	操作模板	验证标准
各维度值直接相加得总量	直接拆解法	变化值/总量变化	各贡献度之和=100%
多个因子相乘得结果	对数差分法	ln(因子变化)/ln(总指标变化)	各因子贡献度之和≈100%
分子分母结构变化	双因素拆解法	指标效应+结构效应	两者之和=实际变化量